

Del dato crudo al pipeline



Lo que va a pasar en estos tramos. La carpeta que armó el jueves se amplía con dos subcarpetas y un archivo, y esa ampliación es la que convierte el sistema en algo que aguanta datos. Después se sube un CSV a un agente que escribe el código por usted, se le piden tres cosas en español, **se lee lo que devolvió**, y se pasa la serie por una lista de chequeo de tres preguntas. Al final el cuaderno queda guardado en su carpeta y `FUENTES.md` tiene su primera ficha llena.

No se necesita instalar nada, ni saber programar, ni pagar. Hace falta una cuenta de Google —la del correo sirve— y el navegador.

Lo que sí se necesita: la carpeta del jueves. Si no la tiene, la plantilla está en `plantilla_sistema/` y en el sitio del curso como ZIP.

0 Antes de empezar

2 min

Lo que hace falta tener abierto:

- El **explorador de archivos** (Explorador de Windows o Finder en Mac), en su carpeta del jueves.
- El **navegador**, con la sesión de Google iniciada.
- `CONTEXT0.md` a la mano. Se sigue pegando al empezar cada conversación nueva. Esa regla no cambió.

Si no trajo datos propios, no se quede quieto. Baje `secop-boyaca.csv` del sitio del curso (`alonsorh-econ.github.io/curso-ia-investigacion-uptc`, sección *Materiales de la sesión 3*) y haga el ejercicio completo con él. Es la misma base del demo, y sirve para las tres trampas.

1 Ampliar la carpeta

8 min

Qué se hace: agregar dos subcarpetas dentro de `04_datos/` y un archivo.

`03_literatura/` **ya existe** desde el jueves —ahí va la tabla de evidencia verificada contra DOI— y hoy no se toca. Lo que se agrega es lo de datos:

```
mi_investigacion/
├── CONTEXT0.md
├── BITACORA.md
├── 00_contexto/
├── 01_ideas/
├── 02_decision/
├── 03_literatura/      ← ya estaba
├── 04_datos/
│   ├── datos.md       ← ya estaba
│   ├── FUENTES.md     ← NUEVO
│   ├── crudo/         ← NUEVO
│   └── limpio/        ← NUEVO
└── 05_salidas/
```

Tres cosas nuevas y nada más: dos carpetas y un archivo de texto.

Qué debe verse en pantalla: al abrir `04_datos/` tienen que aparecer **dos carpetas vacías** — `crudo` y `limpio` — y **dos archivos** — `datos.md` y `FUENTES.md` —. Si `crudo` y `limpio` quedaron en la raíz del proyecto y no dentro de `04_datos/`, córralo ahora: el resto de la guía asume esa ruta.

Por qué dos carpetas y no una. Porque son dos cosas distintas y confundirlas es el error más caro del oficio. En `crudo/` va el archivo **como lo entregó la fuente**. En `limpio/` va lo que salió después de filtrar, recodificar y agregar. Si están en el mismo sitio, en tres semanas usted no va a saber cuál es cuál, y va a analizar el equivocado.

2 La regla del día

3 min

Escríbala de su puño en la primera línea de `FUENTES.md`. Textual:

Lo que entra a `crudo/` no se toca nunca más. Se lee, se transforma, y el resultado va a `limpio/`. Si hay que rehacer, se rehace desde `crudo/`.

Qué prohíbe esta regla, en concreto:

LO QUE SE HACE NORMALMENTE	POR QUÉ ESTÁ PROHIBIDO
Abrir el CSV en Excel y guardar encima	Excel reescribe fechas, convierte códigos en números y borra los ceros a la izquierda. El archivo original deja de existir y usted no se entera.
Borrar filas «que sobran» en el archivo bajado	La exclusión desaparece del registro. Nadie —usted incluido— va a poder decir después qué quedó por fuera.
Renombrar el archivo original para «ordenarlo»	Se pierde el nombre con que la fuente lo entregó, que es parte de la trazabilidad.
Bajar otra vez encima del mismo archivo	Las bases públicas se actualizan hacia atrás. Dos descargas de la misma consulta no son el mismo dato.

Qué debe verse: `04_datos/crudo/` con el archivo tal como se bajó, y con **la misma fecha de modificación del día que se bajó**. Si esa fecha es de hoy y usted lo bajó la semana pasada, algo lo reescribió.

Por qué esto es una regla y no un consejo. Todo el valor de un pipeline está en que se pueda correr otra vez y dé lo mismo. Si el punto de partida cambió, no hay pipeline: hay un resultado que nadie puede reproducir, empezando por usted dentro de seis meses.

3 Colab y el agente que escribe el código

10 min

Qué es. Google Colab es un cuaderno de Python que corre en el navegador: no se instala nada y no consume el computador. Adentro trae un **Data Science Agent** al que se le pide en español lo que uno quiere y él escribe y ejecuta el código.

Qué cuesta. Nada. Hace falta una cuenta de Google y ya. *(La disponibilidad del agente en la versión gratuita puede variar por país y por mes [VERIFICAR] ; si no le aparece el panel del agente, en el Anexo 1 está la salida.)*

Qué se hace:

- Entrar a `colab.research.google.com` e iniciar sesión con la cuenta de Google.
- **Archivo · Nuevo cuaderno.**

- En la barra de la izquierda, el ícono de la **carpeta** (Archivos) → botón de **subir**.
- Subir su CSV —el suyo o `secop-boyaca.csv`—. Esperar a que termine la barra.
- **Anotar el nombre exacto del archivo**, con extensión y con mayúsculas y minúsculas como quedó. Se va a necesitar en los prompts.

Qué debe verse: en el panel de archivos, su CSV listado al mismo nivel que la carpeta `sample_data`. Si no aparece, el cuaderno no ha terminado de conectarse: espere a que el indicador de arriba a la derecha diga que está conectado y vuelva a subirlo.

El archivo que sube a Colab es una copia de trabajo, no el original. El original se queda en `04_datos/crudo/` en su computador. Colab borra lo que usted sube cuando se cierra la sesión, y eso está bien: **no es ahí donde vive su dato.**

4 Los tres prompts

15 min

Los tres van en el **panel del Data Science Agent**, uno después del otro, en la misma sesión. Cambie lo que está entre corchetes por el nombre real de su archivo y de sus columnas.

Prompt 1 · Perfilamiento

Trabaja con el archivo `[nombre_del_archivo.csv]` que acabo de subir.

Antes de calcular nada, descríbeme la base en español:

1. Cuántas filas y cuántas columnas tiene.
2. El nombre de cada columna, su tipo, y cuántos valores faltantes tiene cada una.
3. Para las columnas de texto: cuántos valores distintos hay y cuáles son los cinco más frecuentes.
4. Para las columnas numéricas: mínimo, máximo, mediana y promedio.
5. Si hay una columna de fecha o de año, dime qué período cubre y cuántas filas hay por año.

No interpretes todavía. No me des recomendaciones. Solo descríbeme lo que hay.

Qué debe verse: un número de filas y **la lista completa de columnas**. Léala entera, aunque sean muchas. Este es el único momento del día en que usted va a ver la base tal como es, y las tres trampas del paso 6 se detectan casi siempre aquí, en el conteo de filas por año.

Prompt 2 · La proporción por año

Ahora calcula, sobre esa misma base:

La proporción de [la categoría que le interesa, p. ej. contratos de modalidad "contratación directa"] sobre el total, por cada año.

Devuélvemelo como una tabla con tres columnas: año, número total de filas de ese año, y la proporción. Muéstrame el número absoluto al lado de la proporción, siempre.

Dime explícitamente qué filas quedaron por fuera del cálculo y por qué.

Qué debe verse: tres columnas, no una. **El denominador tiene que estar visible.** Una proporción sin el número de filas del que salió no se puede interpretar: la misma proporción sobre 11 contratos y sobre 338 son dos cosas distintas, y una de las dos no es un hallazgo.

Prompt 3 · El histograma

Hazme un histograma de esa proporción entre [las unidades, p. ej. municipios] para el año [aaaa].

Requisitos:

- Que los ejes digan qué son, en español.
- Que el título diga el año y cuántas unidades entraron.
- Que me digas la mediana, el mínimo y el máximo debajo de la figura.

Y dime cuántas unidades quedaron por fuera de la figura y por qué.

Qué debe verse: una figura **con el número de unidades escrito en el título**. Si el histograma no dice sobre cuántas unidades está construido, no sirve para una presentación ni para un paper: es un dibujo.

El modo típico de fallar. El agente calcula la proporción sobre un total distinto al que usted tenía en la cabeza — por ejemplo, sobre las filas sin valores faltantes en vez de sobre todas— y no lo dice. Por eso los tres prompts terminan con la misma frase: «*dime qué filas quedaron por fuera*». Cuando no la conteste —va a pasar—, se le vuelve a preguntar y se anota en la bitácora.

5 Lea el código

10 min

Modo CRÍTICA. Este es el paso que casi nadie hace, y es el que separa a alguien que usa un agente de alguien que le cree a un agente.

No hay que entender el código línea por línea. No es el objetivo del curso y no lo va a ser hoy. Lo que sí hay que poder decir, mirando el bloque que devolvió, es una sola cosa:

Qué filas cuenta y cuáles deja por fuera.

Qué se hace: desplegar el código que generó el agente —en Colab aparece en la celda, a veces plegada— y hacerle estas tres preguntas. En ese orden.

Las tres preguntas

1. ¿Sobre qué conjunto de filas está calculando?

Busque los filtros: cualquier línea con un `==`, un `>`, un `isin`, un `dropna`, un `query`. Cada una de esas líneas **bota filas**. Súmelas mentalmente: ¿el cálculo es sobre toda la base, o sobre un pedazo? Si es sobre un pedazo, ¿cuál, y quién decidió eso — usted o el agente?

2. ¿Qué hizo con lo que faltaba?

Los valores faltantes se tratan de tres maneras y las tres dan resultados distintos: se botan, se cuentan como cero, o se dejan y contaminan el promedio. Busque `dropna`, `fillna`, `na=`. **Si no aparece ninguna, pregunte.** El silencio también es una decisión, y no la tomó usted.

3. ¿El denominador es el que yo creo que es?

En cualquier proporción, mire de dónde sale el número de abajo. ¿Es el total de filas del año, el total de filas válidas, o el total de la base entera? Las tres son defendibles y dan cifras diferentes. La que no es defendible es no saber cuál se usó.

Cómo se preguntan, si no quiere leer el código: se le devuelven al agente, textuales.

Antes de seguir, respóndeme sobre el código que acabas de correr, en español y sin volver a escribirlo:

1. ¿Sobre qué filas exactamente hizo el cálculo, y cuántas filas de la base original quedaron por fuera?
2. ¿Qué hiciste con los valores faltantes: los botaste, los contaste como cero, o los dejaste?
3. En la proporción, ¿cuál es exactamente el denominador?

Responde con números, no con descripciones. Si alguna de las tres no la puedes responder mirando el código, dilo.

Qué debe verse: tres respuestas **con números**. Si la respuesta a la primera es «se usaron todas las filas», compárela con el conteo del Prompt 1: tienen que coincidir. **Cuando no coinciden, ahí está el hallazgo del día.**

Lo que este paso es. No es desconfianza del agente. El código casi siempre está bien: corre, no da error y produce un número. **El error está en la decisión de qué filas entran, y esa decisión es del investigador aunque la haya tomado la máquina por defecto.**

6 Las tres trampas

10 min

Antes de interpretar cualquier cambio en el tiempo, tres preguntas. Siempre las mismas, en este orden. Se responden por escrito en `FUENTES.md`, aunque la respuesta sea «no».

① ¿Cambió la ESCALA de la medición?

Que la serie suba puede ser que cambió la regla, no el mundo.

El caso real. El ICFES cambió en **2014-2** los puntajes del Saber 11: de puntajes por materia de **0-100** a un global de **100-500**. Graficar 2010-2024 sin saberlo produce un salto espectacular en 2014 que es puro cambio de instrumento.

Y el detalle que lo hace peor: el corte es en el **segundo** semestre. **2014-1 todavía es escala vieja.** Un corte por año calendario parte el problema por la mitad equivocada.

Cómo se detecta: si la serie pega un salto en un punto y **el rango de valores también cambia** —el máximo pasa de 100 a 500—, no es el fenómeno: es la regla de medición.

Qué se hace: buscar en la documentación de la fuente en qué momento exacto cambió, y decidir si se analizan los tramos por separado o si se para la serie antes del corte. **Nunca se promedian los dos tramos.**

② ¿Cambió la COBERTURA — quién entra a la base?

Que aparezcan más casos puede ser que ahora se reportan, no que ahora ocurren.

El caso real. En SECOP, en la muestra laxa el municipio típico pasa de **11 contratos en 2021 a 338 en 2025**, y de **18 % a 81 %** de contratación directa. Parece un cambio de conducta brutal.

Es un municipio que empezó a usar SECOP II. La contratación no cambió: cambió dónde queda registrada.

Cómo se detecta: en el conteo de filas por año del Prompt 1. Si el número de filas se multiplica, la comparación entre años no es entre lo mismo. **Este es el chequeo más barato del día y el que más resultados salva.**

Qué se hace: restringir a las unidades que están presentes en todos los años que se comparan —panel balanceado—, o poner un umbral mínimo de filas por unidad y decirlo. Eso es exactamente lo que va en el campo «decisión de muestra» de `FUENTES.md`.

③ ¿Hay dos POBLACIONES mezcladas en la misma columna?

Que el promedio se mueva puede ser que se están sumando peras con manzanas.

El caso real. Saber 11 en Bogotá: 2010-1 tiene 5.948 estudiantes y 2010-2 tiene 97.444. El primer semestre es calendario B: una población distinta, **dieciséis veces más pequeña** y con **6,7 % de colegios oficiales contra 56,8 %** en el segundo. Promediar «por período» mezcla dos poblaciones.

Cómo se detecta: contar filas por cada valor de la columna que define el período o el grupo. Si un grupo es un orden de magnitud más chico que el otro, casi seguro no son lo mismo. La segunda pista es la composición: si además difieren en una característica básica —oficial vs. privado, urbano vs. rural—, ya no hay duda.

Qué se hace: separarlas, o quedarse con una y decir cuál. **Lo que no se puede es promediarlas sin mirar**, porque el promedio que sale no describe a ninguna de las dos.

La lista, en corto — para pegar al lado de la pantalla

	PREGUNTA	DÓNDE SE VE	SI LA RESPUESTA ES SÍ
①	¿Cambió la escala ?	el rango de valores cambia con el salto	separar tramos, no promediar
②	¿Cambió la cobertura ?	el conteo de filas por año se dispara	panel balanceado o umbral, y decirlo
③	¿Hay dos poblaciones ?	un grupo es un orden de magnitud más chico	separarlas o quedarse con una

Las tres tienen la misma forma. El código estaba bien, corría, no daba error y producía un número. **El error estaba en una decisión que tomó el investigador, no la máquina.**

7 Sacar el cuaderno de Colab

5 min

El cuaderno vive en Google Drive. Eso no es su carpeta. **Hay que bajarlo.**

Qué se hace:

- En Colab: **Archivo · Descargar · Descargar .ipynb**.
- Buscar el archivo en la carpeta de descargas del computador.
- Moverlo a `04_datos/` —no a `crudo/`, no a `limpio/`: a la raíz de `04_datos/` —.
- Renombrarlo con la convención del curso: `aaaa-mm-dd_tema_corto.ipynb`, por ejemplo `2026-09-05_descriptivos_secop.ipynb`.
- Si el agente produjo una tabla o un CSV de resultado, bajarlo también y guardarlo en `04_datos/limpio/`.

Si además quiere poder leerlo sin abrir Colab: *Archivo · Imprimir · Guardar como PDF*, y el PDF al lado del `.ipynb`. El `.ipynb` es el que se vuelve a correr; el PDF es el que se mira. [VERIFICAR] — la ruta del menú de descarga cambia de vez en cuando; si no aparece «Descargar .ipynb», está bajo *Archivo · Guardar una copia en Drive* y de ahí se baja.

Qué debe verse: en `04_datos/`: `FUENTES.md`, `datos.md`, un archivo `.ipynb` con fecha en el nombre, y las dos carpetas. **Y `crudo/` con el archivo original intacto.**

8 Llenar FUENTES.md

5 min

Una ficha por fuente, cuatro campos. El archivo trae un ejemplo lleno de verdad y dos plantillas vacías; se llena la primera vacía.

CAMPO	QUÉ VA	QUÉ NO VA
Fuente	nombre exacto de la base, entidad, enlace o identificador, si pide cuenta	«datos del gobierno»
Fecha de descarga	día, mes y año	«la semana pasada»
Filtro aplicado	qué se pidió y a qué nivel quedó agregado	«se limpió»
Decisión de muestra	qué filas entran y por qué las otras no , con número	«se usaron los datos disponibles»

El cuarto campo es el que cuesta y es el único que no se puede sacar de ningún lado. Es el que responde lo que un evaluador va a preguntar primero. Del ejemplo lleno:

«Para los descriptivos de 2025 se usan solo los 70 municipios con 40 o más contratos en 2025. Los municipios con menos de 40 contratos se excluyen porque su proporción es ruido de denominador chico.»

Ahí hay un umbral, un número de unidades y una razón. Eso es una decisión de muestra.

Qué debe verse: una ficha con los cuatro campos llenos y **un número en el cuarto**. Si el cuarto campo dice «no se excluyó ninguna fila», también sirve — siempre que sea verdad y usted lo haya verificado contra el conteo del Prompt 1.

9 La bitácora

3 min

Una fila por cada vez que le pidió algo al agente. Hoy deberían ser cuatro o cinco.

#	QUÉ PEDÍ	QUÉ DEVOLVIÓ	QUÉ CORREGÍ	POR QUÉ
1	perfilamiento de la base	filas, columnas y faltantes	nada	—
2	proporción por año	la proporción sin el denominador	se lo volví a pedir con el conteo	una proporción sin denominador no se interpreta

«**Qué corregí**» no puede decir «nada» en todas las filas. Si de verdad no corrigió nada, escriba «no corregí nada, y aquí está por qué eso me preocupa».

✓ Al final de estos tramos usted tiene

```
mi_investigacion/
├── 04_datos/
│   ├── FUENTES.md           ← 1 ficha llena, 4 campos
│   ├── datos.md
│   ├── 2026-09-05_descriptivos_XXX.ipynb ← el cuaderno bajado
│   ├── crudo/
│   │   └── [el archivo original, intacto]
│   └── limpio/
│       └── [lo que salió del cuaderno]
└── BITACORA.md              ← 4 o 5 filas más
```

Eso es un pipeline. No hace falta que sea automático para serlo: hace falta que **se pueda volver a correr desde el principio y dé lo mismo**. Con `crudo/` intacto, el cuaderno guardado y `FUENTES.md` diciendo qué se filtró, se puede.

Y lo que sale gratis: cuando le toque escribir la sección de datos del paper, no la va a redactar. La va a leer de `FUENTES.md`. **El pipeline es la descripción del método.**

A1 Anexo 1 · Si no le aparece el Data Science Agent

No se pierde la clase. Tres salidas, en orden de preferencia:

SALIDA	CÓMO	QUÉ SE PIERDE
Colab sin agente	pedirle el código a ChatGPT, Claude o Gemini y pegarlo en una celda del cuaderno	nada de fondo: el paso 5 se vuelve más importante, no menos
Hoja de cálculo	tabla dinámica para el conteo por año y la proporción; histograma con el asistente de gráficos	la reproducibilidad automática; hay que anotar los pasos a mano en <code>FUENTES.md</code>
En pareja	trabajar sobre el cuaderno del compañero, con su base	nada, si los dos leen el código

Las tres trampas del paso 6 se detectan igual en las tres salidas. Son preguntas sobre la muestra, no sobre la herramienta.

A2 Anexo 2 · Los errores que se van a ver hoy

LO QUE PASA	QUÉ SIGNIFICA	QUÉ HACER
El agente devuelve la proporción sin el denominador	Contestó la pregunta, no la necesidad	Volver a pedirlo con el conteo al lado
Dice que usó «todas las filas» pero el número no cuadra con el Prompt 1	Botó filas en silencio, casi siempre faltantes	Preguntarle cuáles y anotarlo en la decisión de muestra
El CSV abre con las tildes rotas	Problema de codificación, no del dato	Pedirle al agente que lo lea con otra codificación; no arreglarlo a mano en el original
Los códigos de municipio perdieron el cero de la izquierda	Alguien lo abrió en Excel y lo guardó	Volver a <code>crudo/</code> . Para eso existe la regla del día
Se cae la conexión de Colab y se pierde el archivo subido	Normal, la sesión caduca	Volver a subir. El original está en <code>crudo/</code> , no se perdió nada
El histograma sale sin decir cuántas unidades tiene	La figura no está terminada	Pedírselo. Sin ese número la figura no se puede mostrar

A3 Anexo 3 · Lo que NO se hizo hoy, y por qué

- **No se instaló Python en el computador.** Se puede, y quien quiera lo hace después. Hoy estorbaba: media clase peleando con una instalación es media clase perdida.
- **No se usó GitHub.** Copilot es gratis para estudiantes verificados por GitHub Education, y Codespaces da un VS Code completo en el navegador — pero **la verificación tarda días**. Queda como el paso siguiente para quien quiera.
- **No se hizo econometría.** Los descriptivos vienen primero, y no como trámite: la mediana de 60,6 % entre municipios, con un rango de 0 % a 83,6 %, **ya es una pregunta de investigación que no existía antes de mirar el dato**.

Guía escrita para la sesión 3. La plantilla `FUENTES.md` y las carpetas `crudo/` y `limpio/` están en `plantilla_sistema/04_datos/` dentro del material del curso, y en el sitio como ZIP. · Alonso Ramírez Hernández · CENES · UPTC · septiembre de 2026 · alonsorh-econ.github.io/curso-ia-investigacion-uptc